

Calidad educativa y desigualdad estructural en Ecuador

Paula Martillo Quintana

June 27, 2026

1 Calidad educativa y desigualdad estructural en Ecuador

1.0.1 Un análisis exploratorio de datos para el concurso Ecuador Cuantificado 2026

Elaborado por Paula Martillo Quintana

Cuando pensamos en educación solemos mirar cuántos años va alguien a la escuela. Pero lo que de verdad mueve el desarrollo y la movilidad social no es la cantidad de años, sino cuánto se aprende en ellos. En Ecuador ese aprendizaje no llega igual a todos: cambia según el dinero de la familia, según la provincia donde se nace y según el tipo de escuela. Quise documentar esas diferencias con datos oficiales y, además, ver qué tan lejos está Ecuador de los países de la región que mejor educan a sus estudiantes.

La pregunta que quiero responder

¿Qué diferencias estructurales separan a Ecuador de los países con mejor desempeño educativo, y cómo se transmiten las desigualdades de origen socioeconómico hacia las oportunidades futuras?

Para responderla reuní microdatos nacionales (INEVAL Ser Estudiante y ENEMDU del INEC), una prueba regional que permite comparar países con la misma vara (ERCE 2019 de la UNESCO) e indicadores internacionales (Banco Mundial, UNESCO-UIS y Our World in Data). Organicé el trabajo en torno a tres preguntas más concretas, que me sirven de guía para saber qué mirar:

1. ¿El nivel socioeconómico de la familia se relaciona con cuánto aprende un estudiante?
2. ¿Un mayor nivel educativo se traduce en mejores ingresos y empleo?
3. ¿Los países que invierten más y tienen clases más pequeñas aprenden más?

Trabajo de forma **descriptiva**: busco patrones y asociaciones, no relaciones de causa y efecto. Lo hago así porque los datos disponibles son una foto de un momento (no siguen a las mismas personas en el tiempo), y forzar una conclusión causal sería deshonesto con lo que realmente puedo ver.

El recorrido tiene cuatro partes: primero **conozco y limpio** cada fuente (qué trae, qué significan sus columnas y qué decisiones tomé para dejarla usable); luego **analizo** las tres preguntas; después **construyo los gráficos** que dan respuesta a cada una; y al final **reúno los hallazgos** en una conclusión.

Repositorio (código y figuras): github.com/bypaupau/concurso-el-quantificador El archivo entregado incluye todos los datos necesarios y el notebook corre de principio a fin, incluso sin conexión a internet.

1.1 0. Preparación

Cargo las librerías y defino unas pocas funciones que voy a reutilizar a lo largo del análisis (por ejemplo, para calcular promedios y medianas usando los pesos muestrales de cada encuesta, y para consultar las APIs).

```
[1]: import os, io, re, json, urllib.request
from pathlib import Path
import warnings
import numpy as np
import pandas as pd
import pyreadstat

warnings.filterwarnings("ignore")
pd.set_option("display.max_columns", 50)
pd.set_option("display.width", 150)

DATA = Path("data_repro")
assert DATA.exists(), "Ejecutar desde la raiz del proyecto (donde esta la
↳ carpeta data_repro/)."
print("Directorio de trabajo:", os.getcwd())
```

Directorio de trabajo: /sessions/eager-fervent-dirac/mnt/concurso-visualizador

```
[2]: # Lectura de las evaluaciones INEVAL: separador ; y coma decimal.
# Los codigos 999999, *999999 y celdas vacias representan ausencia de dato.
NA_INEVAL = ["", " ", "999999", "*999999", "999999.0"]
def leer_ser(path, nrows=None, usecols=None):
    for enc in ("utf-8-sig", "latin-1"):
        try:
            return pd.read_csv(path, sep=";", decimal=",", na_values=NA_INEVAL,
                               encoding=enc, low_memory=False, nrows=nrows,
↳ usecols=usecols)
        except UnicodeDecodeError:
            continue
    raise UnicodeDecodeError("enc", b"", 0, 1, "ni utf-8 ni latin-1")

# Media y mediana ponderadas (las encuestas traen pesos; la mediana ayuda
↳ cuando hay outliers).
def wmean(x, w):
    ok = x.notna() & w.notna()
    return np.average(x[ok], weights=w[ok]) if ok.sum() else np.nan

def wmedian(x, w):
    d = pd.DataFrame({"x": x, "w": w}).dropna().sort_values("x")
    if d.empty:
        return np.nan
    cum = d["w"].cumsum()
```

```

        return d.loc[cum >= d["w"].sum() / 2, "x"].iloc[0]

# Acceso a APIs JSON.
def api_get(url):
    req = urllib.request.Request(url, headers={"Accept": "application/json",
↪ "User-Agent": "Mozilla/5.0"})
    with urllib.request.urlopen(req, timeout=40) as r:
        return json.load(r)

print("Funciones cargadas.")

```

Funciones cargadas.

Antes de graficar, defino un estilo visual único para que todas las figuras se vean consistentes: una paleta sobria, tipografía limpia y un encabezado que coloca título, subtítulo y fuente de forma ordenada.

```

[3]: import logging
import matplotlib.pyplot as plt
logging.getLogger("matplotlib.font_manager").setLevel(logging.ERROR) #
↪ silenciar avisos de fuentes
Path("figuras").mkdir(exist_ok=True)
plt.rcParams.update({"font.family": ["Lato", "Helvetica Neue", "Arial", "DejaVu
↪ Sans"], "font.size": 11.5})
TEAL, DARK, ORANGE, GRAY, INK = "#4E9CA6", "#2C6E78", "#D98A3D", "#6b6b6b",
↪ "#222222"

def wq(x, w, q):
    # percentil ponderado (para boxplots con factor de expansion)
    d = pd.DataFrame({"x": x, "w": w}).dropna().sort_values("x")
    c = (d["w"].cumsum() - 0.5 * d["w"]) / d["w"].sum()
    return float(np.interp(q, c, d["x"]))

def estilo(ax):
    for s in ["top", "right", "left"]:
        ax.spines[s].set_visible(False)
    ax.spines["bottom"].set_color("#cccccc")
    ax.set_axisbelow(True)

def encabezado(fig, titulo, subt, fuente, left=0.12):
    # titulo, subtítulo y fuente juntos arriba/abajo; los ejes se ajustan para
↪ no dejar huecos
    n = titulo.count("\n") + 1
    top = 0.90 - 0.05 * n
    fig.subplots_adjust(top=top, bottom=0.15, left=left, right=0.96)
    fig.text(0.02, 0.985, titulo, va="top", ha="left", fontsize=14.5,
↪ fontweight="bold", color=INK)

```

```

fig.text(0.02, top + 0.035, subt, va="bottom", ha="left", fontsize=9.5,
↪color=GRAY)
fig.text(0.02, 0.02, fuente, va="bottom", ha="left", fontsize=7.6,
↪color="#9a9a9a")

print("Estilo de figuras listo.")

```

Estilo de figuras listo.

```

[4]: def peso_mb(p):
      return round(sum(os.path.getsize(os.path.join(r, f))
                        for r, _, fs in os.walk(p) for f in fs
                        if os.path.exists(os.path.join(r, f)))) / 1e6, 1)

pd.DataFrame([(p.name, peso_mb(p)) for p in sorted(DATA.iterdir()) if p.
↪is_dir()],
              columns=["fuente", "peso_MB"]).sort_values("peso_MB",
↪ascending=False).reset_index(drop=True)

```

```

[4]:

```

	fuente	peso_MB
0	erce-2019	230.3
1	enemdu	118.0
2	ineval-ser-estudiante	14.8
3	sedlac	6.4
4	owid	0.2
5	cuentas-satelites-servicios-educacion	0.0

2 Parte 1. Conocer y limpiar los datos

Antes de analizar nada, abro cada fuente para entenderla: miro sus primeras filas, su tamaño, qué significan sus columnas y cuántos valores faltan. Después, en celdas separadas, dejo a la vista las decisiones de limpieza que tomo. La idea es no calcular nada sobre datos que no entiendo.

2.1 1.1 INEVAL, Ser Estudiante

Evaluación nacional de aprendizajes (Educación General Básica y Bachillerato), con notas por campo y variables de contexto a nivel de estudiante. Cargamos el ciclo 2023-2024 y miramos su tamaño y las primeras columnas (las de contexto y las notas principales).

```

[5]: ser = leer_ser(DATA / "ineval-ser-estudiante" / "2023-2024" / "data.csv")
print("Dimensiones (filas, columnas):", ser.shape)
# Mostramos solo las primeras columnas legibles; el resto se explica abajo
ser[["ciclo", "grado", "estado_eval", "id_prov", "tp_area", "financiamiento",
     "tpsexo", "etnibee", "isec", "quintil", "inev", "imat", "ilyl", "icn"]].
↪head()

```

Dimensiones (filas, columnas): (50545, 78)

```
[5]:      ciclo grado estado_eval id_prov tp_area financiamiento tp_sexo
etnibee      isec quintil  inev  imat  ilyl  icn
0  2023-2024      10          2      1      1          1      1
4.0      NaN      NaN  675.0  697.0  670.0  630.0
1  2023-2024      10          2      1      1          1      1
4.0 -0.150678      3.0  670.0  697.0  656.0  658.0
2  2023-2024      10          2      1      1          1      2
4.0  0.095265      3.0  653.0  700.0  670.0  574.0
3  2023-2024      10          2      1      1          1      1
4.0 -0.277949      2.0  665.0  703.0  656.0  643.0
4  2023-2024      10          2      1      1          1      2
4.0      NaN      NaN  682.0  697.0  713.0  658.0
```

El archivo tiene 78 columnas, muchas de ellas crípticas o casi vacías. Antes de limpiar conviene saber **qué es cada grupo de columnas**. Las agrupamos por su prefijo y explicamos su rol.

```
[6]: cols = list(scr.columns)
notas = ["inev", "imat", "ilyl", "icn", "ifis", "iqui", "ibio", "ies", "ihis",
↪ "ifil", "ied"]
grupos = {
    "Identificacion y contexto": ["ciclo", "grado", "estado_eval", "codigo",
↪ "amie", "nm_regi",
        "es_regeva", "id_zona", "id_dist", "id_prov", "id_cant", "id_parr",
↪ "financiamiento",
        "sostenimiento", "tp_sexo", "na_eano", "tp_area", "etnibee", "isec",
↪ "quintil"],
    "Notas por campo/asignatura": notas,
    "Niveles de logro (nl_)": [c for c in cols if c.startswith("nl_")],
    "Factores de expansion (fex_)": [c for c in cols if c.startswith("fex_")],
    "Rubrica (ind_)": [c for c in cols if c.startswith("ind_")] +
↪ ["estado_rub"],
    "Lista de cotejo (lc_)": [c for c in cols if c.startswith("lc_")] +
↪ ["estado_lc"],
}
for nombre, gs in grupos.items():
    gs = [c for c in gs if c in cols]
    print(f"{nombre} ({len(gs)} columnas): {gs}")
```

Identificacion y contexto (20 columnas): ['ciclo', 'grado', 'estado_eval', 'codigo', 'amie', 'nm_regi', 'es_regeva', 'id_zona', 'id_dist', 'id_prov', 'id_cant', 'id_parr', 'financiamiento', 'sostenimiento', 'tp_sexo', 'na_eano', 'tp_area', 'etnibee', 'isec', 'quintil']

Notas por campo/asignatura (11 columnas): ['inev', 'imat', 'ilyl', 'icn', 'ifis', 'iqui', 'ibio', 'ies', 'ihis', 'ifil', 'ied']

Niveles de logro (nl_) (10 columnas): ['nl_imat', 'nl_ilyl', 'nl_icn', 'nl_ifis', 'nl_iqui', 'nl_ibio', 'nl_ies', 'nl_ihis', 'nl_ifil', 'nl_ied']

Factores de expansion (fex_) (14 columnas): ['fex_inev', 'fex_imat', 'fex_ilyl',

```
'fex_icn', 'fex_ifis', 'fex_iqui', 'fex_ibio', 'fex_ies', 'fex_ihis',
'fex_ifil', 'fex_ied', 'fex_rubrica', 'fex_lista_cotejo',
'fex_honestidad_academica']
Rubrica (ind_) (10 columnas): ['ind_1', 'ind_2', 'ind_3', 'ind_4', 'ind_5',
'ind_6', 'ind_7', 'ind_8', 'ind_9', 'estado_rub']
Lista de cotejo (lc_) (13 columnas): ['lc_1', 'lc_2', 'lc_3', 'lc_4', 'lc_5',
'lc_6', 'lc_7', 'lc_8', 'lc_9', 'lc_10', 'lc_11', 'lc_12', 'estado_lc']
```

Qué significan estos grupos (según el diccionario `diccionario.ods` del ciclo):

- **Identificación y contexto.** `inev` es la nota global; `isec` el índice socioeconómico de INEVAL y quintil su quintil (1 = más bajo, 5 = más alto). `tp_area` (1 rural, 2 urbano), `financiamiento` (1 público, 2 privado, 3 fiscomisional), `tp_sexo` (1 mujer, 2 hombre), `etnibee` (autoidentificación étnica), `nm_regi` (región natural), `grado` (subnivel), `estado_eval` (1 ausente, 2 evaluado).
- **Notas por campo/asignatura.** `imat`, `ilyl`, `icn` son Matemática, Lengua y Literatura, Ciencias Naturales. Las demás (`ifis`, `iqui`, `ibio`, `ihis`, `ifil`, `ied`) son asignaturas **solo de Bachillerato** (Física, Química, Biología, Historia, Filosofía, Educación para la Ciudadanía); por eso están vacías en los grados de básica.
- **Niveles de logro (nl_).** El nivel de desempeño alcanzado en cada campo (categórico).
- **Factores de expansión (fex_).** Pesos muestrales; hay uno por campo. Se usan para que los promedios representen a la población.
- **Rúbrica (ind_) y lista de cotejo (lc_).** Evaluaciones cualitativas que **solo se aplican en ciertos subniveles** (Elemental y Media); por eso están casi siempre vacías.

Esto explica el “muro de NaN” del `head()`: no son datos perdidos al azar, sino columnas que solo aplican a ciertos grados. Lo verificamos midiendo el porcentaje de faltantes por grupo.

```
[7]: for nombre, gs in grupos.items():
      gs = [c for c in gs if c in cols]
      print(f"{nombre:30s} faltante medio: {ser[gs].isna().mean().mean()*100:5.
↪1f}%")
```

Identificacion y contexto	faltante medio:	2.7%
Notas por campo/asignatura	faltante medio:	48.4%
Niveles de logro (nl_)	faltante medio:	52.6%
Factores de expansion (fex_)	faltante medio:	46.2%
Rubrica (ind_)	faltante medio:	13.5%
Lista de cotejo (lc_)	faltante medio:	47.7%

Confirmado: rúbrica, lista de cotejo y las asignaturas de Bachillerato tienen faltantes muy altos porque solo aplican a una parte de los estudiantes. `isec/quintil` tienen ~25% de faltantes porque no todos respondieron la encuesta de factores asociados. Con esto claro, hacemos la limpieza en pasos separados.

Limpieza, paso 1: quedarnos con quienes rindieron la prueba. Los ausentes (`estado_eval = 1`) no tienen notas, así que se excluyen.

```
[8]: print("Antes:", ser.shape[0], "filas")
      ser_eval = ser[ser["estado_eval"] == 2].copy()
```

```
print("Despues de quedarnos con evaluados (estado_eval==2):", ser_eval.
      ↪shape[0], "filas")
print("Estudiantes ausentes descartados:", ser.shape[0] - ser_eval.shape[0])
```

Antes: 50545 filas

Despues de quedarnos con evaluados (estado_eval==2): 48992 filas

Estudiantes ausentes descartados: 1553

Limpieza, paso 2: traducir los códigos a etiquetas legibles. Las variables de contexto vienen como números; creamos columnas con su significado para que el análisis se lea claro.

```
[9]: map_area    = {1: "Rural", 2: "Urbana"}
map_fin      = {1: "Publico", 2: "Privado", 3: "Fiscomisional"}
map_sexo     = {1: "Mujer", 2: "Hombre"}
map_etnia    = {1: "Afroecuatoriano", 2: "Montubio", 3: "Indigena", 4: "Mestizo/
      ↪Blanco", 5: "Otro"}
# nm_regi viene como texto ('1','2',...) y la cadena 'ZONA NO DELIMITADA', no
      ↪como numero
map_region   = {"1": "Costa", "2": "Sierra", "3": "Oriente", "4": "Insular",
      "ZONA NO DELIMITADA": "Zona no delimitada"}
map_grado    = {4: "Basica Elemental", 7: "Basica Media", 10: "Basica Superior",
      ↪3: "Bachillerato"}

ser_eval["area_lbl"]    = ser_eval["tp_area"].map(map_area)
ser_eval["fin_lbl"]    = ser_eval["financiamiento"].map(map_fin)
ser_eval["sexo_lbl"]   = ser_eval["tp_sexo"].map(map_sexo)
ser_eval["etnia_lbl"]  = ser_eval["etnibee"].map(map_etnia)
ser_eval["region_lbl"] = ser_eval["nm_regi"].map(map_region)
ser_eval["grado_lbl"]  = ser_eval["grado"].map(map_grado)

print("Distribucion por grado:")
print(ser_eval["grado_lbl"].value_counts(dropna=False).to_string())
print("\nDistribucion por financiamiento:")
print(ser_eval["fin_lbl"].value_counts(dropna=False).to_string())
```

Distribucion por grado:

grado_lbl	
Basica Media	12565
Basica Elemental	12342
Basica Superior	12319
Bachillerato	11766

Distribucion por financiamiento:

fin_lbl	
Publico	25182
Privado	12896
Fiscomisional	10914

Limpieza, paso 3: seleccionar el subconjunto de análisis. Para R1 nos interesan el contexto, las notas comunes a todos los grados (inev, imat, ilyl, icn), el nivel socioeconómico y el peso. Dejamos fuera rúbrica, lista de cotejo y asignaturas de bachillerato (que solo aplican a subgrupos). Así obtenemos una tabla limpia y manejable.

```
[10]: cols_analisis = ["ciclo", "grado_lbl", "region_lbl", "id_prov", "area_lbl", "fin_lbl",
                    "sexo_lbl", "etnia_lbl", "isec", "quintil", "inev", "imat", "ilyl", "icn",
                    "fex_inev"]
ineval = ser_eval[cols_analisis].copy()
print("Tabla de analisis INEVAL:", ineval.shape)
print("\nFaltantes restantes (%):")
print((ineval.isna().mean() * 100).round(1).to_string())
ineval.head()
```

Tabla de analisis INEVAL: (48992, 15)

Faltantes restantes (%):

ciclo	0.0
grado_lbl	0.0
region_lbl	0.0
id_prov	0.0
area_lbl	0.0
fin_lbl	0.0
sexo_lbl	0.0
etnia_lbl	0.7
isec	23.0
quintil	23.0
inev	3.4
imat	1.4
ilyl	1.4
icn	25.3
fex_inev	3.4

```
[10]:      ciclo      grado_lbl region_lbl id_prov area_lbl fin_lbl sexo_lbl
etnia_lbl  isec quintil  inev  imat  ilyl  icn \
0  2023-2024 Basica Superior   Sierra      1   Rural Publico   Mujer
Mestizo/Blanco      NaN      NaN  675.0  697.0  670.0  630.0
1  2023-2024 Basica Superior   Sierra      1   Rural Publico   Mujer
Mestizo/Blanco -0.150678      3.0  670.0  697.0  656.0  658.0
2  2023-2024 Basica Superior   Sierra      1   Rural Publico  Hombre
Mestizo/Blanco  0.095265      3.0  653.0  700.0  670.0  574.0
3  2023-2024 Basica Superior   Sierra      1   Rural Publico   Mujer
Mestizo/Blanco -0.277949      2.0  665.0  703.0  656.0  643.0
4  2023-2024 Basica Superior   Sierra      1   Rural Publico  Hombre
Mestizo/Blanco      NaN      NaN  682.0  697.0  713.0  658.0
```



```
fex_inev
0    20.7373
1    20.7373
2    20.7373
3    20.7373
4    20.7373
```

Qué queda y para qué sirve: una tabla por estudiante con nota global y por campo, contexto legible, índice socioeconómico y peso muestral. Sirve para R1 (desigualdad interna). Limitaciones: isec/quintil con ~25% de faltantes; la prueba solo cubre a quienes están escolarizados (quien abandonó no aparece, lo que subestima la desigualdad real).

2.2 1.2 ERCE 2019 (UNESCO-LLECE)

Evaluación regional de 6.º (y 3.º) de primaria, con la misma prueba en 16 países, **incluido Ecuador**. Viene en varios archivos .sav: alumno (QA), familia (QF), docente (QD), director (QP) y habilidades socioemocionales (HSE). Vemos qué archivos hay.

```
[11]: erce_dir = DATA / "erce-2019" / "sav"
roles = {"QA": "Cuestionario y puntajes del alumno", "QF": "Cuestionario de la_
        ↪ familia",
        "QD": "Cuestionario del docente", "QP": "Cuestionario del director",
        "HSE": "Habilidades socioemocionales"}
for f in sorted(erce_dir.glob("*.sav")):
    _, meta = pyreadstat.read_sav(str(f), metadataonly=True)
    clave = re.sub(r"ERCE_2019_\|.sav|", "[36]$", "", f.name)
    print(f"{f.name:22s} {meta.number_rows:>6} filas x {meta.number_columns:>4}_
        ↪ cols | {roles.get(clave, '')}")
```

```
ERCE_2019_HSE.sav      80827 filas x   52 cols | Habilidades socioemocionales
ERCE_2019_QA3.sav      80312 filas x   14 cols |
ERCE_2019_QA6.sav      80827 filas x  405 cols |
ERCE_2019_QD3.sav      3776 filas x  161 cols |
ERCE_2019_QD6.sav      3682 filas x  161 cols |
ERCE_2019_QF3.sav      80312 filas x    5 cols |
ERCE_2019_QF6.sav      80827 filas x    5 cols |
ERCE_2019_QP3.sav      3998 filas x  175 cols |
ERCE_2019_QP6.sav      5527 filas x  175 cols |
```

El desempeño cognitivo no se entrega como un único puntaje, sino como cinco **valores plausibles** por dominio (representaciones de la habilidad del estudiante, propias de las pruebas estandarizadas). El puntaje del estudiante es el promedio de los cinco. Los dominios son Matemática (MAT), Lenguaje (LAN) y Ciencias (SCI). Cargamos el archivo de alumno de 6.º.

```
[12]: dom = ["MAT", "LAN", "SCI"]
pv = [f"{d}_{i}" for d in dom for i in range(1, 6)]
qa6, meta_qa = pyreadstat.read_sav(str(erce_dir / "ERCE_2019_QA6.sav"),
```

```

        usecols=["IDSTUD", "IDCNTRY", "COUNTRY",
        ↪"WT"] + pv)
print("Dimensiones QA6 (alumno 6.º):", qa6.shape)
print("Significado de las columnas clave:")
print(" IDSTUD: identificador del estudiante | IDCNTRY/COUNTRY: pais | WT:
        ↪peso muestral")
print(" MAT_1..MAT_5:", meta_qa.column_names_to_labels["MAT_1"], "(y sus 5
        ↪valores plausibles)")
print(" Países presentes:", sorted(qa6["COUNTRY"].unique()))
qa6.head()

```

Dimensiones QA6 (alumno 6.º): (80827, 19)

Significado de las columnas clave:

IDSTUD: identificador del estudiante | IDCNTRY/COUNTRY: pais | WT: peso muestral

MAT_1..MAT_5: Matemáticas (valor plausible 1) (y sus 5 valores plausibles)

Países presentes: ['ARG', 'BRA', 'COL', 'CRI', 'CUB', 'DOM', 'ECU', 'GTM', 'HND', 'MEX', 'NIC', 'PAN', 'PER', 'PRY', 'SLV', 'URY']

```

[12]:
      IDSTUD  IDCNTRY COUNTRY          WT  MAT_1  MAT_2  MAT_3  MAT_4  MAT_5
LAN_1 LAN_2 LAN_3 LAN_4 LAN_5 SCI_1 SCI_2 SCI_3 SCI_4 SCI_5
0  10010502.0    170.0    COL  210.639991  587.8  635.4  630.4  499.3  612.1
716.0  655.3  684.2  644.8  680.6  642.5  618.3  536.5  596.1  630.5
1  10010503.0    170.0    COL  210.639991  749.5  699.4  668.5  644.0  643.4
845.8  827.0  799.3  812.5  852.4  786.0  781.5  740.9  731.4  720.9
2  10010504.0    170.0    COL  210.639991  687.4  687.6  710.2  711.8  637.9
710.0  724.1  643.0  655.5  690.4  616.8  692.0  589.3  685.3  637.3
3  10010505.0    170.0    COL  210.639991  791.7  769.3  763.0  763.2  799.5
769.6  671.0  653.6  707.0  784.1  787.7  754.0  767.0  766.1  781.6
4  10010506.0    170.0    COL  210.639991  703.0  713.7  667.6  729.7  668.5
772.4  787.5  741.1  772.6  779.5  716.9  801.0  718.1  696.3  741.4

```

```

[13]: # Limpieza: el puntaje por dominio es el promedio de los 5 valores plausibles
for d in dom:
    qa6[d] = qa6[[f"{d}_{i}" for i in range(1, 6)]].mean(axis=1)
print("Faltantes en los puntajes derivados (%):", (qa6[dom].isna().mean() *
        ↪100).round(2).to_dict())
print("\nEstadísticas de los puntajes (escala ~700):")
print(qa6[dom].describe().round(0).to_string())

```

Faltantes en los puntajes derivados (%): {'MAT': 0.0, 'LAN': 0.0, 'SCI': 0.0}

Estadísticas de los puntajes (escala ~700):

	MAT	LAN	SCI
count	80827.0	80827.0	80827.0
mean	700.0	702.0	706.0
std	93.0	104.0	90.0

min	372.0	285.0	360.0
25%	634.0	624.0	644.0
50%	690.0	700.0	702.0
75%	758.0	779.0	765.0
max	1067.0	1035.0	1092.0

El cuestionario de familia (QF6) trae las variables socioeconómicas que ni INEVAL ni otras fuentes locales ofrecían de forma interpretable.

```
[14]: qf6, meta_qf = pyreadstat.read_sav(str(erce_dir / "ERCE_2019_QF6.sav"),
                                         usecols=["IDSTUD", "IDCNTRY", "ISECF",
                                         ↪ "FFIT11", "FFIT19"])
print("Significado de las columnas del cuestionario de familia:")
for v in ["ISECF", "FFIT11", "FFIT19"]:
    print(f"    {v}: {meta_qf.column_names_to_labels[v]}")
print("\nNiveles de educacion de la madre (FFIT11):")
for k, val in meta_qf.variable_value_labels["FFIT11"].items():
    print(f"    {int(k):>2}: {val}")
```

Significado de las columnas del cuestionario de familia:

ISECF: Índice socioeconómico de la familia

FFIT11: ¿Cuál es el nivel educativo más alto que la madre del estudiante ha alcanzado?

FFIT19: ¿Cuántos libros hay en la casa del estudiante? Considere todos los tipos de libro: poesía, novelas, diccionarios, libros de estudio, etc.

Niveles de educacion de la madre (FFIT11):

- 1: No tiene estudios
- 2: <CINE-P 1-2> incompleta.
- 3: <CINE-P 1-2> completa.
- 4: <CINE-P 3> incompleta.
- 5: <CINE-P 3> completa.
- 6: <CINE-P 4> incompleta.
- 7: <CINE-P 4> completa.
- 8: <CINE-P 5-6> incompleta.
- 9: <CINE-P 5-6> completa.
- 10: <CINE-P 7-8> incompleto.
- 11: <CINE-P 7-8> completo.
- 12: No sé/No aplica

Limpieza/unión importante. El identificador IDSTUD se repite entre países, así que para unir puntaje (QA) con familia (QF) hay que usar la clave compuesta IDSTUD + IDCNTRY. Si se uniera solo por IDSTUD, las filas se multiplicarían. Lo comprobamos.

```
[15]: solo_id = qa6.merge(qf6, on="IDSTUD", how="inner")
con_pais = qa6.merge(qf6, on=["IDSTUD", "IDCNTRY"], how="inner")
print("Uniendo solo por IDSTUD:      ", solo_id.shape[0], "filas (inflado, ↪
    ↪ incorrecto)")
```

```
print("Uniendo por IDSTUD + IDCNTY: ", con_pais.shape[0], "filas (correcto, ~80.827)")
erce = con_pais
```

Uniendo solo por IDSTUD: 345505 filas (inflado, incorrecto)

Uniendo por IDSTUD + IDCNTY: 80827 filas (correcto, ~80.827)

Para qué sirve: relacionar, a nivel de estudiante, el aprendizaje con el nivel socioeconómico de la familia y la educación de los padres (R1), y comparar a Ecuador con la región usando la misma prueba. Limitaciones: solo primaria, diseño transversal, Chile no participó en 2019; usar pesos WT y los cinco valores plausibles.

2.3 1.3 ENEMDU 2023 (INEC). mercado laboral

Encuesta de hogares anual del INEC. La uso para ver la relación entre el nivel educativo y el ingreso o el empleo. Cargo las columnas relevantes y explicamos cada una.

```
[16]: enemdu_sav = (DATA / "enemdu" / "6.Bases de datos de salida o de difusión" /
                "BDDenemdu_personas_2023_anual.sav")
cols_en = ["prov", "area", "p02", "p03", "nnivins", "ingrl", "conduct",
            "empleo",
            "fexp", "upm", "estrato"]
enem, meta_en = pyreadstat.read_sav(str(enemdu_sav), usecols=cols_en)
print("Dimensiones (personas 2023 anual):", enem.shape)
print("\nSignificado de las columnas:")
descr = {"prov": "Provincia", "area": "Area (1 urbana, 2 rural)", "p02": "Sexo (1 hombre, 2 mujer)",
        "p03": "Edad", "nnivins": "Nivel de instruccion", "ingrl": "Ingreso laboral mensual",
        "conduct": "Condicion de actividad (empleo/subempleo/desempleo/inactivo)",
        "empleo": "Indicador de poblacion con empleo", "fexp": "Factor de expansion (peso)",
        "upm": "Unidad primaria de muestreo", "estrato": "Estrato muestral"}
for v in cols_en:
    print(f" {v:9s}: {descr[v]}")
enem.head()
```

Dimensiones (personas 2023 anual): (345174, 11)

Significado de las columnas:

```
prov      : Provincia
area      : Area (1 urbana, 2 rural)
p02       : Sexo (1 hombre, 2 mujer)
p03       : Edad
nnivins   : Nivel de instruccion
ingrl     : Ingreso laboral mensual
conduct   : Condicion de actividad (empleo/subempleo/desempleo/inactivo)
```

empleo : Indicador de poblacion con empleo
 fexp : Factor de expansion (peso)
 upm : Unidad primaria de muestreo
 estrato : Estrato muestral

```
[16]: area p02 p03 estrato fexp nnivins ingrl conduct empleo prov
upm
0 1.0 2.0 78.0 2713 5.564878 3.0 NaN 9.0 NaN 1.0
010150000201
1 1.0 1.0 79.0 2713 5.564878 3.0 NaN 9.0 NaN 1.0
010150000201
2 1.0 2.0 73.0 2713 5.564878 3.0 NaN 9.0 NaN 1.0
010150000201
3 1.0 1.0 46.0 2713 5.564878 5.0 646.0 1.0 1.0 1.0
010150000201
4 1.0 2.0 59.0 2713 5.564878 5.0 NaN 9.0 NaN 1.0
010150000201
```

```
[17]: # Codigos de las dos variables categoricas que mas usaremos
print("Nivel de instruccion (nnivins):")
for k, v in meta_en.variable_value_labels["nnivins"].items():
    print(f" {int(k)}: {v}")
print("\nCondicion de actividad (conduct):")
for k, v in meta_en.variable_value_labels["conduct"].items():
    print(f" {int(k)}: {v}")
print("\nFaltantes (%):")
print((enem[["nnivins", "ingrl", "conduct", "fexp"]].isna().mean() * 100).
      round(1).to_string())
```

Nivel de instruccion (nnivins):

- 1: Ninguno
- 2: Centro de Alfabetización
- 3: Educacion Básica
- 4: Educacion Media/Bachillerato
- 5: Superior

Condicion de actividad (conduct):

- 0: Menores de 15 años
- 1: Empleo Adecuado/Pleno
- 2: Subempleo por insuficiencia de tiempo de trabajo
- 3: Subempleo por insuficiencia de ingresos
- 4: Otro empleo no pleno
- 5: Empleo no remunerado
- 6: Empleo no clasificado
- 7: Desempleo abierto
- 8: Desempleo oculto
- 9: Población Económicamente Inactiva

```
Faltantes (%):
nnivins      5.9
ingrl        57.2
conduct      0.0
fexp         0.0
```

El ingreso laboral (`ingrl`) tiene ~57% de faltantes (es natural: solo lo tienen quienes perciben ingreso laboral) y, además, arrastra códigos de ausencia y outliers. Si se calcula la media en crudo sale un número absurdo. Lo mostramos antes de limpiar.

```
[18]: print("Ingreso laboral (ingrl) en crudo:")
print(enem["ingrl"].describe().round(1).to_string())
print("\nCodigo 999999 (no responde):", int((enem["ingrl"] == 999999).sum()),
      "| valores negativos (-1):", int((enem["ingrl"] < 0).sum()))
print("La media cruda (~4166) es implausible para un ingreso mensual en Ecuador:
      ↪",
      "esta contaminada por esos codigos y por outliers extremos.")
```

Ingreso laboral (`ingrl`) en crudo:

```
count      147643.0
mean        4165.7
std         60114.4
min          -1.0
25%         200.0
50%         440.0
75%         652.0
max         999999.0
```

Codigo 999999 (no responde): 536 | valores negativos (-1): 1420

La media cruda (~4166) es implausible para un ingreso mensual en Ecuador: esta contaminada por esos codigos y por outliers extremos.

Limpieza en pasos: (1) descartar códigos de ausencia y outliers (`ingrl` fuera de $0 < x < 99999$); (2) quedarnos con personas adultas (18+); (3) traducir nivel y condición a etiquetas. Mostramos el efecto en el número de filas.

```
[19]: en = enem.copy()
print("Filas totales:", len(en))

# Paso 1: ingreso valido
en["ingrl_val"] = en["ingrl"].where((en["ingrl"] > 0) & (en["ingrl"] < 99999))
print("Con ingreso laboral valido (0 < ingrl < 99999):", int(en["ingrl_val"].
      ↪notna().sum()))

# Paso 2: adultos con ingreso valido
adultos = en[(en["ingrl_val"].notna()) & (en["p03"] >= 18)].copy()
print("Adultos (18+) con ingreso valido:", len(adultos))

# Paso 3: etiquetas legibles
```

```

adultos["nivel_lbl"] = adultos["nnivins"].map(meta_en.
  ↪variable_value_labels["nnivins"])
adultos["conduct_lbl"] = adultos["conduct"].map(meta_en.
  ↪variable_value_labels["conduct"])
adultos["sexo_lbl"] = adultos["p02"].map({1: "Hombre", 2: "Mujer"})
adultos["area_lbl"] = adultos["area"].map({1: "Urbana", 2: "Rural"})
adultos[["p03", "sexo_lbl", "area_lbl", "nivel_lbl", "ingrl_val", "fexp"]].
  ↪head()

```

Filas totales: 345174

Con ingreso laboral valido (0 < ingrl < 99999): 142835

Adultos (18+) con ingreso valido: 142131

```

[19]:      p03 sexo_lbl area_lbl      nivel_lbl ingrl_val      fexp
      3  46.0  Hombre  Urbana      Superior      646.0  5.564878
      9  51.0   Mujer  Urbana Educacion Básica      810.0  5.564878
     10  34.0   Mujer  Urbana      Superior      365.0  5.564878
     12  50.0   Mujer  Urbana      Superior      450.0  5.564878
     13  36.0  Hombre  Urbana      Superior      470.0  5.564878

```

Tras limpiar, la media y la mediana del ingreso difieren mucho (por la asimetría), así que para el análisis se usará la **mediana ponderada**, no la media. Variables de diseño obligatorias: **fexp**, **upm**, **estrato**. Limitación de fondo: ENEMDU mide el **nivel** educativo, no la calidad del aprendizaje, así que R2 describe el retorno del nivel alcanzado, no de la calidad.

```

[20]: print("Comparacion media vs mediana del ingreso laboral limpio (adultos):")
      print("  media  :", round(adultos["ingrl_val"].mean(), 0))
      print("  mediana:", round(adultos["ingrl_val"].median(), 0), "(mas_
      ↪representativa)")

```

Comparacion media vs mediana del ingreso laboral limpio (adultos):

media : 555.0

mediana: 450.0 (mas representativa)

2.4 1.4 Our World in Data (OWID)

Tres descargas locales con cobertura global (incluido Ecuador): años de escolaridad ajustados por aprendizaje (LAYS), gasto educativo y ratio alumno-docente. Estructura simple (Entity, Code, Year, valor).

```

[21]: for fname, desc in [("years-of-schooling.csv", "LAYS (anios ajustados por_
      ↪aprendizaje)" ),
      ("education-spending.csv", "Gasto educativo (% PIB)" ),
      ("pupil-teacher-ratio-for-primary-education-by-country.
      ↪csv", "Ratio alumno-docente")]:
      d = pd.read_csv(DATA / "owid" / fname)
      print(f"{desc}: {d.shape} | columnas: {list(d.columns)} | ECU presente:
      ↪{(d['Code']=='ECU').any()}")

```

LAYS (años ajustados por aprendizaje): (601, 4) | columnas: ['Entity', 'Code', 'Year', 'Both genders'] | ECU presente: True
 Gasto educativo (% PIB): (5205, 4) | columnas: ['Entity', 'Code', 'Year', 'Total across all levels of education'] | ECU presente: True
 Ratio alumno-docente: (1383, 4) | columnas: ['Entity', 'Code', 'Year', 'Pupil-qualified teacher ratio in primary education'] | ECU presente: True

2.5 1.5 SEDLAC (CEDLAS / Banco Mundial)

Estadísticas armonizadas de encuestas de hogares de América Latina, ya tabuladas (años de educación, salarios, alfabetismo). Comparación regional para R2. Vienen como Excel con hojas.

```
[22]: for f in sorted((DATA / "sedlac").glob("*.xlsx")):
      print(f"{f.name}: hojas {pd.ExcelFile(f).sheet_names[:7]}")
```

```
2025_Act1_employment_LAC.xlsx: hojas ['Index', 'labor force', 'employment',
'unemployment', 'duration', 'change', 'structure']
2025_Act1_enrollment_LAC.xlsx: hojas ['index', 'gender', 'income', 'area',
'primary', 'secondary', 'tertiary']
2025_Act1_literacy_LAC.xlsx: hojas ['index', 'age_gender', 'income', 'area']
2025_Act1_wages_hours_LAC.xlsx: hojas ['Index', 'wage_1', 'wage_2', 'wage_3',
'wage_4', 'hours_1', 'hours_2']
2025_Act1_years_edu_LAC.xlsx: hojas ['index', 'structure', 'years',
'age_gender', 'income', 'income_age', 'area']
```

2.6 1.6 Cuentas Satélite de Educación (INEC)

Detalle nacional del gasto educativo 2007-2024. Importante mostrar que **no** viene como tabla limpia, sino como cuadros de reporte con encabezados y codificación latina: requiere limpieza (saltar filas de título, fijar encabezados, corregir codificación) antes de usarse. Para la serie comparable conviene apoyarse en OWID/Banco Mundial.

```
[23]: cse = (DATA / "cuentas-satelites-servicios-educacion" / "data" /
      "6_Indicadores_FyE_CSE_2007-24" / "1.1_GNE_PIB.csv")
crudo = pd.read_csv(cse, sep=";", encoding="latin-1", header=None, nrows=8)
print("Las primeras filas son titulos y metadatos, no datos:")
crudo.iloc[:6, :6]
```

Las primeras filas son titulos y metadatos, no datos:

```
[23]:
```

	0	1	2	3	4	5
0	Índice	NaN	NaN	NaN	NaN	NaN
1		NaN	NaN	NaN	NaN	NaN
2	CUADRO N°	1.1	NaN	NaN	NaN	NaN
3	Gasto Nacional en Educación según sector públi...	NaN	NaN	NaN	NaN	NaN
4		NaN	NaN	NaN	NaN	NaN
5	Miles de dólares	NaN	NaN	NaN	NaN	NaN

Decisión sobre las Cuentas Satélite. Como se ve, el archivo son cuadros de reporte (filas de título y metadatos, celdas vacías), no una tabla analizable directamente. Reestructurarlas es costoso y, para la serie de gasto comparable entre países, OWID y el Banco Mundial ya la ofrecen lista. Por eso **esta fuente no se usa en los gráficos finales**; se documenta por transparencia. El “muro de NaN” no es un error de lectura: refleja ese formato de reporte.

2.7 1.7 APIs: Banco Mundial y UNESCO UIS

Para indicadores internacionales que no están en las descargas locales se usan dos APIs. Siguiendo la regla del proyecto, antes de programar se prueba la conexión, se mira un ejemplo de respuesta y se inspeccionan las columnas.

Banco Mundial. La respuesta es una lista [metadatos, registros].

```
[24]: def wb_get(indicador, paises="ECU", date="2010:2023"):
    data = api_get(f"https://api.worldbank.org/v2/country/{paises}/indicator/{indicador}"
                  f"?format=json&date={date}&per_page=500")
    if not isinstance(data, list) or len(data) < 2 or data[1] is None:
        return pd.DataFrame()
    return pd.DataFrame([{"pais": x["countryiso3code"], "anio": int(x["date"]),
                          "valor": x["value"]} for x in data[1]])

try:
    ejemplo = wb_get("SE.XPD.TOTL.GD.ZS", "ECU", "2018:2022")
    print("Conexion Banco Mundial OK. Columnas:", list(ejemplo.columns))
    display(ejemplo.dropna(subset=["valor"]).sort_values("anio"))
except Exception as e:
    print("Sin conexion al Banco Mundial; el analisis usara el cache local_
    (api_cache.csv).")
    print("Detalle:", repr(e)[:90])
```

Conexion Banco Mundial OK. Columnas: ['pais', 'anio', 'valor']

	pais	anio	valor
4	ECU	2018	4.625026
3	ECU	2019	4.245770
2	ECU	2020	4.261030
1	ECU	2021	3.656490
0	ECU	2022	3.613020

UNESCO UIS. Su documentación es una página Swagger, pero expone un esquema OpenAPI legible que enumera endpoints y parámetros. Detalle aprendido al probar: para varios países el separador de geoUnit es la coma, no +.

```
[25]: UIS = "https://api.uis.unesco.org/api/public"

def uis_get(indicador, geo="ECU", start=2015, end=2024):
    geo = ",".join(geo) if isinstance(geo, (list, tuple)) else geo
```

```

data = api_get(f"{UIS}/data/indicators?indicator={indicador}&geoUnit={geo}"
               f"&start={start}&end={end}&indicatorMetadata=false")
return pd.DataFrame(data.get("records", []))

try:
    schema = api_get(UIS.replace("/api/public", "") + "/api/public/openapi/
↳schema.json")
    print("UIS API:", schema["info"]["title"], schema["info"]["version"])
    for path in schema["paths"]:
        print("  GET", path)
    print("\nEjemplo: finalizacion de secundaria alta (CR.3) en Ecuador")
    print(uis_get("CR.3", "ECU", 2018, 2024).dropna(subset=["value"]).tail(4).
↳to_string(index=False))
except Exception as e:
    print("Sin conexion a UNESCO-UIS; el analisis usara el cache local_
↳(api_cache.csv).")
    print("Detalle:", repr(e)[:90])

```

UIS API: UIS Data API 1.0.2

```

GET /api/public/data/indicators
GET /api/public/data/indicators/export
GET /api/public/definitions/geounits
GET /api/public/definitions/geounits/export
GET /api/public/definitions/indicators
GET /api/public/definitions/indicators/export
GET /api/public/versions/default
GET /api/public/versions

```

Ejemplo: finalizacion de secundaria alta (CR.3) en Ecuador

indicatorId	geoUnit	year	value	magnitude	qualifier
CR.3	ECU	2021	79.100000	None	None
CR.3	ECU	2022	80.500000	None	None
CR.3	ECU	2023	79.700000	None	None
CR.3	ECU	2024	80.765068	None	None

3 Parte 2. Análisis de las tres preguntas

Con los datos ya limpios, empiezo a responder mis tres preguntas con cálculos descriptivos, mostrando los números detrás de cada uno. Todavía no son conclusiones cerradas: voy anotando lo que observo y también lo que cada resultado no permite afirmar.

3.1 2.1 ¿El origen socioeconómico marca cuánto se aprende?

Es la pregunta central de mi trabajo. La miro en dos planos: la desigualdad **dentro de Ecuador** (con INEVAL, estudiante por estudiante) y la posición de Ecuador **frente a la región** (con ERCE, la misma prueba en 16 países). Todos los promedios usan los pesos muestrales. Defino una función de apoyo para no repetir el patrón “promedio ponderado por grupo”.

```
[26]: def nota_por(df, grupo, nota, peso):
        return (df.dropna(subset=[grupo, nota])
                .groupby(grupo)
                .apply(lambda d: pd.Series({"nota": round(wmean(d[nota],
↪d[peso]), 1), "n": len(d)}),
                    include_groups=False)
                .sort_values("nota"))

# Nombres de provincia (id_prov viene como entero)
prov_nombres = {1: "Azuay", 2: "Bolivar", 3: "Canar", 4: "Carchi", 5:
↪"Cotopaxi", 6: "Chimborazo",
                7: "El Oro", 8: "Esmeraldas", 9: "Guayas", 10: "Imbabura", 11: "Loja", 12:
↪"Los Rios",
                13: "Manabi", 14: "Morona Santiago", 15: "Napo", 16: "Pastaza", 17:
↪"Pichincha",
                18: "Tungurahua", 19: "Zamora Chinchipe", 20: "Galapagos", 21: "Sucumbios",
↪22: "Orellana",
                23: "Santo Domingo", 24: "Santa Elena", 90: "Zona no delimitada"}
ineval["prov_lbl"] = ineval["id_prov"].map(prov_nombres)
print("Funcion de apoyo y mapa de provincias listos.")
```

Funcion de apoyo y mapa de provincias listos.

3.1.1 2.1.1 Desigualdad dentro de Ecuador (INEVAL)

El corte base: nota global por quintil socioeconómico.

```
[27]: print("Nota global por quintil socioeconomico (1=mas bajo, 5=mas alto):")
print(nota_por(ineval, "quintil", "inev", "fex_inev").to_string())
```

Nota global por quintil socioeconomico (1=mas bajo, 5=mas alto):

	nota	n
quintil		
1.0	681.0	7542.0
2.0	684.5	7542.0
3.0	688.1	7542.0
4.0	695.0	7542.0
5.0	701.9	7542.0

¿En qué campo pesa más la desigualdad socioeconómica? Comparamos la brecha quintil 5 - quintil 1 en Matemática, Lengua y Ciencias.

```
[28]: for materia in ["imat", "ilyl", "icn"]:
        t = nota_por(ineval, "quintil", materia, "fex_inev")["nota"]
        print(f"    {materia}: brecha Q5-Q1 = {round(t.loc[5] - t.loc[1], 1)}
↪puntos")
```

```
imat: brecha Q5-Q1 = 11.8 puntos
ilyl: brecha Q5-Q1 = 35.5 puntos
```

icn: brecha Q5-Q1 = 30.2 puntos

Cortes territoriales y de tipo de escuela. Advertencia: **no son independientes** del nivel socioeconómico (lo urbano y lo privado concentran familias de mayor quintil), así que mezclan varios factores. Son descripción, no efecto aislado.

```
[29]: print("Por area:")
print(nota_por(ineval, "area_lbl", "inev", "fex_inev").to_string())
print("\nPor financiamiento de la escuela:")
print(nota_por(ineval, "fin_lbl", "inev", "fex_inev").to_string())
print("\nPor region natural:")
print(nota_por(ineval, "region_lbl", "inev", "fex_inev").to_string())
```

Por area:

	nota	n
area_lbl		
Rural	684.6	16880.0
Urbana	688.4	30459.0

Por financiamiento de la escuela:

	nota	n
fin_lbl		
Publico	683.6	24402.0
Fiscomisional	690.8	10587.0
Privado	703.7	12350.0

Por region natural:

	nota	n
region_lbl		
Zona no delimitada	678.0	163.0
Insular	681.8	192.0
Oriente	682.1	2907.0
Costa	686.0	20110.0
Sierra	690.8	23967.0

```
[30]: # Desigualdad territorial fina: provincias con mejor y peor desempeno
prov = nota_por(ineval, "prov_lbl", "inev", "fex_inev")
print("5 provincias con menor nota:")
print(prov.head(5).to_string())
print("\n5 provincias con mayor nota:")
print(prov.tail(5).to_string())
print("\nDiferencia provincia mas alta - mas baja:",
      round(prov['nota'].iloc[-1] - prov['nota'].iloc[0], 1), "puntos")
```

5 provincias con menor nota:

	nota	n
prov_lbl		
Esmeraldas	671.2	2532.0
Napo	674.0	436.0

El Oro	677.1	1234.0
Orellana	677.2	425.0
Sucumbios	677.7	580.0

5 provincias con mayor nota:

	nota	n
prov_lbl		
Bolivar	694.8	349.0
Chimborazo	696.7	1238.0
Imbabura	698.2	1432.0
Canar	699.3	438.0
Cotopaxi	699.8	938.0

Diferencia provincia mas alta - mas baja: 28.6 puntos

```
[31]: print("Nota global por autoidentificacion etnica:")
      print(nota_por(ineval, "etnia_lbl", "inev", "fex_inev").to_string())
```

Nota global por autoidentificacion etnica:

	nota	n
etnia_lbl		
Afroecuatoriano	677.7	2334.0
Montubio	681.6	2704.0
Otro	681.9	1140.0
Indigena	686.9	2242.0
Mestizo/Blanco	688.9	38614.0

Lectura de 2.1.1: el desempeño se estratifica de forma consistente por nivel socioeconómico, área, sostenimiento, territorio y etnia. La desigualdad pega algo más fuerte en Lengua que en Matemática. Son cortes descriptivos y correlacionados entre sí; no aíslan el efecto de ninguna variable.

3.1.2 2.1.2 Ecuador frente a la región (ERCE 2019)

Puntaje medio de cada país en los tres dominios.

```
[32]: dom = ["MAT", "LAN", "SCI"]
      punt = pd.DataFrame({d: erce.groupby("COUNTRY").apply(
          lambda g: wmean(g[d], g["WT"]), include_groups=False) for d in dom})
      print("Puntaje medio ponderado por pais (ERCE 2019, 6.º grado):")
      print(punt.round(0).sort_values("MAT", ascending=False).to_string())
```

Puntaje medio ponderado por pais (ERCE 2019, 6.º grado):

	MAT	LAN	SCI
COUNTRY			
PER	759.0	741.0	723.0
URY	759.0	734.0	731.0
MEX	758.0	726.0	726.0

BRA	733.0	734.0	718.0
CRI	726.0	757.0	758.0
ECU	720.0	684.0	720.0
COL	707.0	719.0	711.0
ARG	690.0	698.0	682.0
CUB	689.0	738.0	779.0
HND	682.0	661.0	674.0
SLV	676.0	699.0	705.0
NIC	663.0	654.0	669.0
GTM	657.0	645.0	661.0
PRY	647.0	657.0	657.0
PAN	645.0	652.0	672.0
DOM	636.0	644.0	649.0

```
[33]: media_reg = punt.drop(index="ECU").mean()
comp = pd.DataFrame({"Ecuador": punt.loc["ECU"], "Media_region": media_reg,
                    "Brecha": punt.loc["ECU"] - media_reg}).round(1)
print("Ecuador vs promedio regional (sin Ecuador):")
print(comp.to_string())
```

Ecuador vs promedio regional (sin Ecuador):

	Ecuador	Media_region	Brecha
MAT	719.8	695.2	24.6
LAN	684.3	697.3	-13.1
SCI	720.1	701.1	19.0

Hallazgo: Ecuador está por encima del promedio regional en Matemática y Ciencias, pero por debajo en Lenguaje. La debilidad relativa está en lectura, y **coincide** con lo que mostró INEVAL (la desigualdad también pegaba más en Lengua), aunque son pruebas y años distintos: convergencia de indicios, no una medición única.

Gradiente socioeconómico dentro de Ecuador con ERCE, en los tres dominios.

```
[34]: ecu = erce[erce["COUNTRY"] == "ECU"].copy()
ecu["q_isec"] = pd.qcut(ecu["ISECF"], 5, labels=[1, 2, 3, 4, 5])
grad = pd.DataFrame({d: ecu.groupby("q_isec", observed=True).apply(
    lambda g: wmean(g[d], g["WT"]), include_groups=False) for d in dom})
print("ERCE (Ecuador): puntaje por quintil socioeconomico familiar (ISECF)")
print(grad.round(0).to_string())
print("\nBrecha quintil 5 - quintil 1 por dominio:")
print((grad.loc[5] - grad.loc[1]).round(0).to_string())
```

ERCE (Ecuador): puntaje por quintil socioeconomico familiar (ISECF)

	MAT	LAN	SCI
q_isec			
1	686.0	637.0	685.0
2	699.0	662.0	697.0
3	717.0	684.0	716.0
4	739.0	712.0	741.0

5 770.0 742.0 774.0

Brecha quintil 5 - quintil 1 por dominio:

MAT 84.0
LAN 105.0
SCI 89.0

```
[35]: # El mismo gradiente segun educacion de la madre, agrupada en tres niveles
def grupo_madre(v):
    if pd.isna(v) or v == 12: # 12 = No sabe / No aplica
        return np.nan
    if v <= 3: return "1. Hasta primaria"
    if v <= 7: return "2. Secundaria"
    return "3. Superior"
ecu["educ_madre"] = ecu["FFIT11"].map(grupo_madre)
print("Matematica segun nivel educativo de la madre (Ecuador):")
print(nota_por(ecu.rename(columns={"MAT": "mat"}), "educ_madre", "mat", "WT").
      ↪to_string())
```

Matematica segun nivel educativo de la madre (Ecuador):

	nota	n
educ_madre		
1. Hasta primaria	699.7	2426.0
2. Secundaria	725.4	2465.0
3. Superior	778.3	1085.0

¿Qué tan desigual es Ecuador frente a sus pares? Brecha Q5-Q1 dentro de cada país.

```
[36]: def brecha_pais(df, dominio="MAT"):
    filas = []
    for c, g in df.groupby("COUNTRY"):
        gg = g.dropna(subset=["ISECF", dominio])
        if len(gg) < 200:
            continue
        gg = gg.assign(q=pd.qcut(gg["ISECF"], 5, labels=[1, 2, 3, 4, 5]))
        mq = gg.groupby("q", observed=True).apply(
            lambda h: wmean(h[dominio], h["WT"]), include_groups=False)
        filas.append((c, round(mq.loc[5] - mq.loc[1], 0)))
    return pd.DataFrame(filas, columns=["pais", "brecha_Q5_Q1"]).
    ↪sort_values("brecha_Q5_Q1", ascending=False)

br = brecha_pais(erce, "MAT").reset_index(drop=True)
print("Brecha socioeconomica Q5-Q1 en Matematica, por pais (1 = mas desigual):")
print(br.to_string(index=False))
print("\nPosicion de Ecuador:", int(br.query("pais=='ECU').index[0]) + 1,
      ↪"de", len(br))
```

Brecha socioeconomica Q5-Q1 en Matematica, por pais (1 = mas desigual):

pais	brecha_Q5_Q1
BRA	140.0
URY	126.0
PAN	118.0
GTM	114.0
COL	112.0
PER	109.0
CRI	107.0
SLV	94.0
ARG	92.0
ECU	84.0
MEX	84.0
PRY	80.0
DOM	75.0
HND	38.0
CUB	35.0
NIC	31.0

Posicion de Ecuador: 10 de 16

Síntesis de R1: Ecuador rinde en la zona media de la región, con debilidad marcada en lectura, y su desempeño está fuertemente estratificado por nivel socioeconómico (familia y educación de la madre). En desigualdad interna no es de los más desiguales de la región, pero la brecha sigue siendo grande en términos absolutos (del orden de dos años de escolaridad entre el quintil más rico y el más pobre).

Límites: todo es asociación, no causalidad; los cortes están correlacionados entre sí; ERCE es solo primaria y de 2019, INEVAL es 2023-2024; la evaluación no ve a quienes ya abandonaron, lo que subestima la desigualdad real.

3.1.3 2.1.3 Primera visualización: las brechas por factor

Convertimos los hallazgos de R1 en un gráfico que responde una pregunta concreta: ¿qué factores estructurales se asocian con las mayores brechas de aprendizaje en Ecuador? Se calcula, para cada factor, la diferencia en la nota global entre el grupo más y el menos favorecido, y se exporta a PNG para el concurso.

```
[37]: def brecha(grupo, alto, bajo):
    t = nota_por(ineval, grupo, "inev", "fex_inev")["nota"]
    return round(t.loc[alto] - t.loc[bajo], 1)

prov_t = nota_por(ineval, "prov_lbl", "inev", "fex_inev")["nota"]
gaps = {
    "Territorio\n(provincia mejor vs peor)": round(prov_t.max() - prov_t.min(), 1),
    "Nivel socioeconómico\n(quintil 5 vs 1)": brecha("quintil", 5.0, 1.0),
    "Tipo de escuela\n(privada vs pública)": brecha("fin_lbl", "Privado", "Publico"),
```



```

    "Etnia\n(mestizo/blanco vs afro)": brecha("etnia_lbl", "Mestizo/Blanco",
↪ "Afroecuatoriano"),
    "Área\n(urbana vs rural)": brecha("area_lbl", "Urbana", "Rural"),
}
# Se imprimen los valores que alimentan el grafico (todo sale de INEVAL, nada
↪ esta fijado a mano)
print("Brecha en la nota global (puntos), por factor:")
for k, v in sorted(gaps.items(), key=lambda kv: -kv[1]):
    print(f"  {k.splitlines()[0]:22s} {v:>5}")

items = sorted(gaps.items(), key=lambda kv: kv[1])  # ascendente: la brecha
↪ mayor queda arriba
labels, vals = [k for k, _ in items], [v for _, v in items]

fig, ax = plt.subplots(figsize=(8.6, 5.0))
bars = ax.barh(labels, vals, color=TEAL, height=0.62, zorder=3)
bars[-1].set_color(DARK)  # resaltar la brecha mayor
for b, v in zip(bars, vals):
    ax.text(v + 0.5, b.get_y() + b.get_height() / 2, f"{v:g} pts",
            va="center", ha="left", fontsize=11, fontweight="bold", color=INK)
ax.set_xlim(0, max(vals) * 1.18)
ax.set_xlabel("Diferencia en la nota global (puntos)", fontsize=10, color=GRAY)
estilo(ax); ax.tick_params(axis="y", length=0, labelsize=10.5)
ax.tick_params(axis="x", colors=GRAY, labelsize=9.5); ax.xaxis.grid(True,
↪ color="#ECECEC")
encabezado(fig, "El territorio y el origen social marcan las mayores\nbrechas
↪ de aprendizaje en Ecuador",
            "Diferencia en la nota global entre el grupo más y el menos
↪ favorecido de cada factor (INEVAL 2023-2024)",
            "Fuente: INEVAL, Ser Estudiante 2023-2024. Promedios ponderados.
↪ Diferencias descriptivas, correlacionadas entre sí. Elaborado por Paula
↪ Martillo Quintana.",
            left=0.27)
fig.savefig("figuras/01_brechas_factores.png", dpi=200, bbox_inches="tight",
↪ facecolor="white")
plt.show()


```

Brecha en la nota global (puntos), por factor:

Territorio	28.6
Nivel socioeconómico	20.9
Tipo de escuela	20.1
Etnia	11.2
Área	3.8

El territorio y el origen social marcan las mayores brechas de aprendizaje en Ecuador

Diferencia en la nota global entre el grupo más y el menos favorecido de cada factor (INEVAL 2023-2024)



Fuente: INEVAL, Ser Estudiante 2023-2024. Promedios ponderados. Diferencias descriptivas, correlacionadas entre sí. Elaborado por Paula Martillo Quintana.

Qué dice este gráfico. Ordena los factores por el tamaño de la brecha en la nota global. El territorio (28.6 puntos entre la mejor y la peor provincia) y el nivel socioeconómico de la familia (20.9 puntos entre el quintil más rico y el más pobre) son las dos divisiones más grandes; el tipo de escuela queda muy cerca. En cambio, el área urbano/rural por sí sola apenas separa (3.9 puntos). Esto sostiene la primera parte de la tesis: en Ecuador, lo que más predice el aprendizaje es de dónde viene el estudiante, no tanto si vive en ciudad o campo.

Dos advertencias para leerlo bien: las diferencias están **correlacionadas entre sí** (lo privado y lo urbano concentran familias de mayor quintil), así que no son el efecto aislado de cada factor; y son **descriptivas**, no causales.

3.2 2.2 ¿Más educación se traduce en más oportunidades?

Con la ENEMDU ya limpia, miro la mediana del ingreso laboral según el nivel educativo alcanzado (usando el factor de expansión para que represente a la población).

```
[38]: r2 = (adultos.dropna(subset=["nivel_lbl", "fexp"])
      .groupby("nnivins")
      .apply(lambda d: pd.Series({
          "nivel": d["nivel_lbl"].iloc[0],
          "ingreso_mediana": round(wmedian(d["ingrl_val"], d["fexp"])),
          "n": len(d)}), include_groups=False))
print("ENEMDU 2023: ingreso laboral (mediana ponderada) por nivel educativo")
print(r2[["nivel", "ingreso_mediana", "n"]].to_string(index=False))
```

ENEMDU 2023: ingreso laboral (mediana ponderada) por nivel educativo

	nivel	ingreso_mediana	n
	Ninguno	140.0	2698
	Centro de Alfabetización	97.0	201
	Educacion Básica	280.0	47848
	Educacion Media/Bachillerato	420.0	48603
	Superior	650.0	42781

Lectura preliminar y límites: el ingreso sube con el nivel educativo. Mide el retorno del **nivel** alcanzado (no de la calidad, que ENEMDU no observa); es transversal y no corrige el sesgo de selección de quienes no trabajan.

3.3 2.3 ¿Más recursos significan más aprendizaje?

Esta pregunta la miro entre países: ¿los que más invierten o tienen clases más pequeñas aprenden más? Armo una tabla con el último dato de cada indicador de Our World in Data.

```
[39]: def owid_latest(fname, valcol, nuevo):
    d = pd.read_csv(DATA / "owid" / fname).rename(columns={valcol: nuevo}).
    ↪dropna(subset=[nuevo])
    return d.sort_values("Year").groupby("Code").tail(1).
    ↪set_index("Code")[nuevo]

panel = pd.concat([
    owid_latest("years-of-schooling.csv", "Both genders", "LAYS"),
    owid_latest("education-spending.csv", "Total across all levels of_
    ↪education", "gasto_pib"),
    owid_latest("pupil-teacher-ratio-for-primary-education-by-country.csv",
    ↪"Pupil-qualified teacher ratio in primary education",_
    ↪"ratio_ad"),
], axis=1).dropna(subset=["LAYS"])

print("Panel pais (", panel.shape[0], "países ). Correlaciones con LAYS:")
print(panel.corr(numeric_only=True)["LAYS"].round(2).to_string())
print("\nEcuador y comparadores:")
print(panel.reindex(["ECU", "CHL", "PER", "COL", "KOR", "FIN"]).round(2).
    ↪to_string())
```

Panel pais (174 países). Correlaciones con LAYS:

LAYS	1.00
gasto_pib	0.13
ratio_ad	-0.56

Ecuador y comparadores:

	LAYS	gasto_pib	ratio_ad
Code			
ECU	8.70	3.69	23.25
CHL	9.41	4.91	18.18
PER	8.63	4.36	21.38

COL	8.62	5.26	23.46
KOR	11.68	5.41	14.48
FIN	11.74	6.38	NaN

Lectura preliminar y límites: aparece la asociación esperada (más gasto y menos alumnos por docente van con más aprendizaje), pero es a nivel país (ecológica), con pocos casos y sin controlar por el ingreso del país. Sirve para ubicar a Ecuador, no para afirmar causalidad.

4 Parte 3. Los gráficos que dan respuesta a las preguntas

Hasta aquí entendí y limpié los datos y exploré cada relación con tablas. Ahora traduzco esos hallazgos a gráficos, uno por pregunta, para que la historia se lea de un vistazo. Cada figura parte de los datos ya limpios de las secciones anteriores y se guarda como imagen en `figuras/`.

Empiezo confirmando que el estilo visual y las funciones de apoyo siguen disponibles.

```
[40]: print("Estilo y funciones de figuras disponibles desde la preparacion:",
        ↪ "encabezado" in dir())
```

Estilo y funciones de figuras disponibles desde la preparacion: True

4.0.1 Gráfico 2. La desigualdad no mueve solo el promedio, mueve toda la distribución


Pregunta: ¿la ventaja socioeconómica mueve solo el promedio o toda la distribución de notas?

```
[41]: qd = ineval.dropna(subset=["quintil", "inev", "fex_inev"])
stats = []
for q in [1, 2, 3, 4, 5]:
    g = qd[qd["quintil"] == q]
    stats.append(dict(label=f"Q{q}", med=wq(g["inev"], g["fex_inev"], .5),
                      q1=wq(g["inev"], g["fex_inev"], .25), q3=wq(g["inev"],
↪ g["fex_inev"], .75),
                      whislo=wq(g["inev"], g["fex_inev"], .10),
↪ whishi=wq(g["inev"], g["fex_inev"], .90), fliers=[]))
fig, ax = plt.subplots(figsize=(8.6, 5.6))
ax.bxp(stats, patch_artist=True, widths=0.55, showfliers=False,
        boxprops=dict(facecolor=TEAL, edgecolor=DARK),
↪ medianprops=dict(color=INK, linewidth=2),
        whiskerprops=dict(color=DARK), capprops=dict(color=DARK))
ax.set_ylabel("Nota global", color=GRAY)
ax.set_xlabel("Quintil socioeconómico (1=más pobre, 5=más rico)", color=GRAY)
estilo(ax); ax.yaxis.grid(True, color="#ECECEC")
encabezado(fig, "La ventaja socioeconómica desplaza toda la distribución de
↪ notas",
            "Nota global por quintil (caja = p25-p75, línea = mediana, bigotes =
↪ p10-p90), INEVAL Ser Estudiante 2023-2024",
            "Fuente: INEVAL, Ser Estudiante 2023-2024. Percentiles ponderados
↪ por el factor de expansión. Elaborado por Paula Martillo Quintana.")
```

```
fig.savefig("figuras/02_boxplot_quintil.png", dpi=200, bbox_inches="tight",
           facecolor="white")
plt.show()
```

La ventaja socioeconómica desplaza toda la distribución de notas

Nota global por quintil (caja = p25-p75, línea = mediana, bigotes = p10-p90), INEVAL Ser Estudiante 2023-2024



Fuente: INEVAL, Ser Estudiante 2023-2024. Percentiles ponderados por el factor de expansión. Elaborado por Paula Martillo Quintana.

Qué dice este gráfico. No es solo que el promedio suba con el quintil: **toda la distribución se desplaza**. La mediana pasa de ~679 (Q1) a ~699 (Q5), y las cajas (el 50% central) casi no se solapan entre extremos. Es decir, un estudiante típico del quintil más alto rinde por encima de buena parte de los del quintil más bajo. Un boxplot es el gráfico adecuado aquí porque muestra la **dispersión**, no solo el centro, y deja ver que la desigualdad es estructural, no un puñado de casos atípicos.

4.0.2 Gráfico 3. Ecuador frente a la región (dumbbell, comparación internacional)

¿En qué áreas Ecuador supera o no al promedio de los países de la región? Se usa ERCE porque es la única fuente que aplica **la misma prueba** en 16 países, lo que hace la comparación válida.

```
[42]: dom = ["MAT", "LAN", "SCI"]; nom = {"MAT": "Matemática", "LAN": "Lenguaje",
      ↪ "SCI": "Ciencias"}
pp = erce.groupby("COUNTRY").apply(lambda g: pd.Series({d: wmean(g[d], g["WT"])
      ↪ for d in dom}), include_groups=False)
ecuv, regv = pp.loc["ECU"], pp.drop(index="ECU").mean()
fig, ax = plt.subplots(figsize=(8.6, 4.8))
for i, d in enumerate(dom):
```


```

ax.plot([regv[d], ecuv[d]], [i, i], color="#d2d2d2", lw=2.5, zorder=1)
ax.scatter(regv[d], i, s=140, color=GRAY, zorder=2)
ax.scatter(ecuv[d], i, s=140, color=DARK, zorder=3)
ax.text(ecuv[d], i + 0.22, f"{ecuv[d]:.0f}", ha="center", fontsize=10,
color=DARK, fontweight="bold")
ax.text(regv[d], i - 0.30, f"{regv[d]:.0f}", ha="center", fontsize=9.5,
color=GRAY)
ax.set_yticks(range(len(dom))); ax.set_yticklabels([nom[d] for d in dom]); ax.
set_ylim(-0.6, 2.7)
ax.scatter([], [], color=DARK, s=140, label="Ecuador"); ax.scatter([], [],
color=GRAY, s=140, label="Promedio de la región")
ax.legend(loc="upper left", frameon=False, fontsize=10, bbox_to_anchor=(0, 1.
02))
ax.set_xlabel("Puntaje ERCE", color=GRAY); estilo(ax); ax.xaxis.grid(True,
color="#ECECEC"); ax.tick_params(axis="y", length=0)
encabezado(fig, "Ecuador supera a la región en Matemática y Ciencias,\npero se
queda atrás en Lectura",
"Puntaje promedio en 6.º grado, Ecuador vs promedio de los países de la
región, ERCE 2019",
"Fuente: UNESCO-LLECE, ERCE 2019. Promedio regional = media de los
15 países comparadores. Elaborado por Paula Martillo Quintana.")
fig.savefig("figuras/03_ecuador_vs_region.png", dpi=200, bbox_inches="tight",
facecolor="white")
plt.show()

```

Ecuador supera a la región en Matemática y Ciencias, pero se queda atrás en Lectura

Puntaje promedio en 6.º grado, Ecuador vs promedio de los países de la región, ERCE 2019



Fuente: UNESCO-LLECE, ERCE 2019. Promedio regional = media de los 15 países comparadores. Elaborado por Paula Martillo Quintana.

Qué dice este gráfico. Ecuador queda por encima del promedio regional en Matemática (720 vs 695) y Ciencias (720 vs 701), pero **por debajo en Lenguaje** (684 vs 697). La debilidad relativa del país está en lectura. Es un hallazgo que **coincide** con lo visto en INEVAL (la desigualdad pegaba más fuerte en Lengua): dos fuentes distintas, años distintos, apuntando a lo mismo. No es una medición única, sino una convergencia de indicios.


4.0.3 Gráfico 4. Ranking regional en Matemática (barras, comparación internacional)

¿En qué lugar de la región se ubica Ecuador? El ranking ordena los 16 países por su puntaje medio en Matemática y resalta a Ecuador.

```
[43]: mat = erce.groupby("COUNTRY").apply(lambda g: wmean(g["MAT"], g["WT"]),
    ↪include_groups=False).sort_values()
fig, ax = plt.subplots(figsize=(8.6, 7))
colors = [DARK if c == "ECU" else "#cfdfe2" for c in mat.index]
ax.barh(mat.index, mat.values, color=colors, height=0.7)
ax.text(mat["ECU"] + 4, list(mat.index).index("ECU"), "Ecuador", va="center",
    ↪color=DARK, fontweight="bold", fontsize=10)
ax.set_xlabel("Puntaje en Matemática", color=GRAY); ax.set_xlim(600, 780)
estilo(ax); ax.xaxis.grid(True, color="#ECECEC"); ax.tick_params(axis="y",
    ↪length=0, labelsize=10)
encabezado(fig, "Ecuador se ubica en la mitad de la tabla regional\nen
    ↪Matemática",
            "Puntaje promedio en Matemática, 6.º grado, por país, ERCE 2019",
            "Fuente: UNESCO-LLECE, ERCE 2019. Promedios ponderados. Elaborado
    ↪por Paula Martillo Quintana.")
fig.savefig("figuras/04_ranking_paises.png", dpi=200, bbox_inches="tight",
    ↪facecolor="white")
plt.show()
```

Ecuador se ubica en la mitad de la tabla regional en Matemática

Puntaje promedio en Matemática, 6.º grado, por país, ERCE 2019



Fuente: UNESCO-LLECE, ERCE 2019. Promedios ponderados. Elaborado por Paula Martillo Quintana.

Qué dice este gráfico. Ecuador se ubica a media tabla regional en Matemática: por encima de países como Guatemala, Panamá o República Dominicana, pero por debajo de Perú, Uruguay, México o Costa Rica. No es ni el mejor ni el peor de la región; está en una posición intermedia que deja margen claro de mejora respecto a los líderes.

4.0.4 Gráfico 5. Ingreso por nivel educativo (boxplot, R2)

¿Cómo se relaciona el nivel educativo alcanzado con el ingreso laboral? Se usa ENEMDU porque es la encuesta oficial que mide ingreso y educación a nivel de persona; se usa la **mediana** (no la media) por la fuerte asimetría de los ingresos.

```
[44]: orden = [1, 3, 4, 5] # se omite Centro de Alfabetización (n pequeño)
nombres = {1: "Ninguno", 3: "Básica", 4: "Bachillerato", 5: "Superior"}
st = []
for nv in orden:
    g = adultos[adultos["nnivins"] == nv]
    st.append(dict(label=nombres[nv], med=wq(g["ingrl_val"], g["fexp"], .5),
                q1=wq(g["ingrl_val"], g["fexp"], .25), q3=wq(g["ingrl_val"],
                g["fexp"], .75),
```




```

        whislo=wq(g["ingrl_val"], g["fexp"], .10),
        ↳whishi=wq(g["ingrl_val"], g["fexp"], .90), fliers=[]))
fig, ax = plt.subplots(figsize=(8.6, 5.6))
ax.bxp(st, vert=False, patch_artist=True, widths=0.55, showfliers=False,
        boxprops=dict(facecolor=ORANGE, edgecolor="#9c5e1f"),
        ↳medianprops=dict(color=INK, linewidth=2),
        whiskerprops=dict(color="#9c5e1f"), capprops=dict(color="#9c5e1f"))
for i, s in enumerate(st):
    ax.text(s["med"], i + 1.28, f"mediana ${s['med']:.0f}", ha="center",
        ↳fontsize=9, color="#9c5e1f")
ax.set_xlabel("Ingreso laboral mensual (USD)", color=GRAY); estilo(ax); ax.
    ↳axis.grid(True, color="#ECECEC")
encabezado(fig,"A mayor nivel educativo, mayor ingreso laboral",
            "Ingreso laboral mensual por nivel de instrucción, adultos con
        ↳ingreso positivo (caja=p25-p75, bigotes=p10-p90), ENEMDU 2023",
            "Fuente: INEC, ENEMDU 2023 anual. Percentiles ponderados por el
        ↳factor de expansión. Mide nivel alcanzado, no calidad. Elaborado por Paula
        ↳Martillo Quintana.")
fig.savefig("figuras/05_boxplot_ingreso.png", dpi=200, bbox_inches="tight",
    ↳facecolor="white")
plt.show()

```

A mayor nivel educativo, mayor ingreso laboral

Ingreso laboral mensual por nivel de instrucción, adultos con ingreso positivo (caja=p25-p75, bigotes=p10-p90), ENEMDU 2023



Fuente: INEC, ENEMDU 2023 anual. Percentiles ponderados por el factor de expansión. Mide nivel alcanzado, no calidad. Elaborado por Paula Martillo Quintana.

Qué dice este gráfico. El ingreso laboral crece con cada nivel educativo: la mediana pasa de

~\$140 (sin estudios) a ~\$280 (básica), ~\$420 (bachillerato) y ~\$650 (superior). La caja de “Superior” además se estira mucho hacia la derecha (mayor techo de ingresos). Esto conecta la educación con las **oportunidades** (R2). Importante: ENEMDU mide el **nivel** educativo alcanzado, no la calidad del aprendizaje, así que esto habla del retorno de completar más años/niveles, no de aprender mejor; y como es transversal, no corrige que quienes no trabajan no aparecen.


4.0.5 Gráfico 6. Recursos y resultados (scatter, R3)

A nivel país, ¿el aprendizaje se asocia con la cantidad de alumnos por docente? Se usa OWID porque ofrece el indicador LAYS (aprendizaje comparable) y la ratio alumno-docente para casi 130 países.

```
[45]: sc = panel.dropna(subset=["LAYS", "ratio_ad"])
fig, ax = plt.subplots(figsize=(8.6, 6))
ax.scatter(sc["ratio_ad"], sc["LAYS"], s=30, color="#cfdfe2",
           edgecolor="white", zorder=2)
foco = {"ECU": ("Ecuador", (8, -17), DARK, "bold"), "PER": ("Perú", (-40, -15),
           ORANGE, "normal"),
        "COL": ("Colombia", (10, 7), ORANGE, "normal"), "CHL": ("Chile", (8,
           6), ORANGE, "normal"),
        "KOR": ("Corea", (8, 5), ORANGE, "normal"), "FIN": ("Finlandia", (6,
           -16), ORANGE, "normal")
for c, (lab, off, col, fw) in foco.items():
    if c in sc.index:
        ax.scatter(sc.loc[c, "ratio_ad"], sc.loc[c, "LAYS"], s=95, color=col,
           zorder=3, edgecolor="white")
        ax.annotate(lab, (sc.loc[c, "ratio_ad"], sc.loc[c, "LAYS"]),
           xytext=off, textcoords="offset points",
           fontsize=10, fontweight=fw, color=col)
ax.set_xlabel("Alumnos por docente (primaria)", color=GRAY)
ax.set_ylabel("Años de escolaridad ajustados por aprendizaje (LAYS)",
           color=GRAY)
estilo(ax); ax.grid(True, color="#F2F2F2")
r = sc["LAYS"].corr(sc["ratio_ad"])
encabezado(fig, "Donde hay más alumnos por docente, \nel aprendizaje tiende a ser
           menor",
           f"Aprendizaje (LAYS) frente a la ratio alumno-docente, por país
           (correlación = {r:.2f})",
           "Fuente: Our World in Data (último dato por país). Asociación a
           nivel país, no causal. Elaborado por Paula Martillo Quintana.")
fig.savefig("figuras/06_scatter_recursos.png", dpi=200, bbox_inches="tight",
           facecolor="white")
plt.show()
```

Donde hay más alumnos por docente, el aprendizaje tiende a ser menor

Aprendizaje (LAYS) frente a la ratio alumno-docente, por país (correlación = -0.56)



Fuente: Our World in Data (último dato por país). Asociación a nivel país, no causal. Elaborado por Paula Martillo Quintana.

Qué dice este gráfico. Hay una asociación negativa moderada (correlación -0.56): los países con más alumnos por docente tienden a aprender menos. Ecuador (23 alumnos por docente) se ubica en el grupo intermedio, lejos del rincón superior izquierdo donde están Corea y Finlandia (pocos alumnos por docente y alto aprendizaje). Es una relación **ecológica** (a nivel país, no de estudiante), con pocos casos y sin controlar por el ingreso del país, así que describe dónde está Ecuador, no demuestra que reducir el tamaño de la clase cause más aprendizaje.

4.0.6 Gráfico 7. Inversión educativa en el tiempo (línea, R3)

¿Cómo ha evolucionado el gasto público en educación de Ecuador? Un gráfico de líneas es el adecuado para ver evolución temporal.

```
[46]: gs = pd.read_csv(DATA / "owid" / "education-spending.csv").
      ↪ rename(columns={"Total across all levels of education": "gasto"})
ge = gs[gs["Code"] == "ECU"].dropna(subset=["gasto"]).sort_values("Year")
ge = ge[ge["Year"] >= 2000]
fig, ax = plt.subplots(figsize=(8.6, 5))
ax.plot(ge["Year"], ge["gasto"], color=DARK, lw=2.5, zorder=3)
ax.scatter(ge["Year"].iloc[[-1]], ge["gasto"].iloc[[-1]], color=DARK, s=50,
      ↪ zorder=4)
ax.annotate(f"{ge['gasto'].iloc[-1]:.1f}% ({int(ge['Year'].iloc[-1])})",
```


```

        (ge["Year"].iloc[-1], ge["gasto"].iloc[-1]), xytext=(-12, 9),
        ↪textcoords="offset points",
        fontsize=10, color=DARK, fontweight="bold")
ax.set_ylabel("Gasto público en educación (% del PIB)", color=GRAY); ax.
    ↪set_xlabel("Año", color=GRAY)
ax.set_ylim(0, ge["gasto"].max() * 1.2); estilo(ax); ax.yaxis.grid(True,
    ↪color="#ECECEC")
encabezado(fig, "La inversión educativa de Ecuador ronda el 4% del PIB",
            "Gasto público en educación como porcentaje del PIB, Ecuador",
            "Fuente: Our World in Data / UNESCO. Elaborado por Paula Martillo
    ↪Quintana.")
fig.savefig("figuras/07_linea_gasto.png", dpi=200, bbox_inches="tight",
    ↪facecolor="white")
plt.show()

```

La inversión educativa de Ecuador ronda el 4% del PIB

Gasto público en educación como porcentaje del PIB, Ecuador



Fuente: Our World in Data / UNESCO. Elaborado por Paula Martillo Quintana.

Qué dice este gráfico. Tras crecer fuerte en los 2000, la inversión educativa de Ecuador alcanzó un pico cercano al 5% del PIB hacia 2014-2015 y desde entonces ha descendido hasta rondar el 3.7% en el dato más reciente. El contexto importa para R3: Ecuador no solo invierte menos que el país líder de la región, sino que su esfuerzo relativo ha venido **cayendo** en los últimos años.

4.0.7 Gráfico 8. Ecuador frente al país mejor educado de la región (gráfico central)

Este es el gráfico que responde de forma más directa la pregunta de investigación. Primero se **determina con datos** cuál es el país de mejor desempeño educativo de América Latina (el de mayor LAYS), y luego se comparan los factores estructurales de Ecuador frente a ese país.

```
[47]: lays_all = (pd.read_csv(DATA / "owid" / "years-of-schooling.csv")
        .rename(columns={"Both genders": "LAYS"}).dropna(subset=["LAYS"]))
lays_all = lays_all.sort_values("Year").groupby("Code").tail(1)
latam = ["ARG", "BOL", "BRA", "CHL", "COL", "CRI", "CUB", "DOM", "ECU", "SLV",
        ↪ "GTM",
        "HND", "MEX", "NIC", "PAN", "PRY", "PER", "URY", "VEN"]
lays_latam = (lays_all[lays_all["Code"].isin(latam)]
        .set_index("Code")["LAYS"].sort_values(ascending=False))
mejor = lays_latam.index[0]
print("Aprendizaje (LAYS) en America Latina, ranking (top 6):")
print(lays_latam.round(2).head(6).to_string())
print("\nPais mejor educado de la region:", mejor, "( LAYS =", round(lays_latam.
        ↪ iloc[0], 2), ")")
```

Aprendizaje (LAYS) en America Latina, ranking (top 6):

Code	
CHL	9.41
CRI	8.99
MEX	8.82
ECU	8.70
PER	8.63
COL	8.62

Pais mejor educado de la region: CHL (LAYS = 9.41)

```
[48]: # Estas funciones intentan la API en vivo y, si no hay internet, leen el cache
        ↪ local
# (data_repro/api_cache.csv). Asi el notebook se reproduce 100% offline.
CACHE = pd.read_csv(DATA / "api_cache.csv")
def _cache(src, ind, geo):
    m = CACHE[(CACHE["source"] == src) & (CACHE["indicator"] == ind) &
        ↪ (CACHE["geo"] == geo)]
    return float(m["value"].iloc[0]) if len(m) else np.nan

def wb_last(ind, code):
    try:
        d = wb_get(ind, code).dropna(subset=["valor"])
        if len(d):
            return d.sort_values("anio")["valor"].iloc[-1]
    except Exception:
        pass
    return _cache("WB", ind, code)

def uis_last(ind, code):
    try:
        d = uis_get(ind, code).dropna(subset=["value"])
        if len(d):
```

```

        return d.sort_values("year")["value"].iloc[-1]
    except Exception:
        pass
    return _cache("UIS", ind, code)

# Seis factores estructurales comparables (Ecuador vs el mejor país)
F = [
    ("Aprendizaje (LAYS, años)", panel.loc["ECU", "LAYS"], panel.
    ↪loc[mejor, "LAYS"], "{:.1f}", False),
    ("Gasto educativo (% PIB)", panel.loc["ECU", "gasto_pib"], panel.
    ↪loc[mejor, "gasto_pib"], "{:.1f}%", False),
    ("Acceso a internet (% pob.)", wb_last("IT.NET.USER.ZS", "ECU"),
    ↪wb_last("IT.NET.USER.ZS", mejor), "{:.0f}%", False),
    ("Matrícula terciaria (% bruta)", wb_last("SE.TER.ENRR", "ECU"),
    ↪wb_last("SE.TER.ENRR", mejor), "{:.0f}%", False),
    ("Finaliz. secundaria alta (%)", uis_last("CR.3", "ECU"),
    ↪uis_last("CR.3", mejor), "{:.0f}%", False),
    ("Alumnos por docente", panel.loc["ECU", "ratio_ad"], panel.
    ↪loc[mejor, "ratio_ad"], "{:.0f}", True),
]
nombre = {"CHL": "Chile", "CRI": "Costa Rica", "URY": "Uruguay", "MEX":
    ↪"México", "PER": "Perú"}.get(mejor, mejor)

print(f"Factores estructurales: Ecuador vs {nombre} (valores que alimentan el
    ↪grafico)")
for nom, e, c, fmt, low in F:
    print(f" {nom:32s} ECU={e:7.1f} {mejor}={c:7.1f}")

fig, axes = plt.subplots(2, 3, figsize=(10.5, 7))
for ax, (nom, e, c, fmt, low) in zip(axes.flat, F):
    ax.bar([0, 1], [e, c], color=[TEAL, ORANGE], width=0.62, zorder=3)
    for x, v in zip([0, 1], [e, c]):
        ax.text(x, v + max(e, c) * 0.03, fmt.format(v), ha="center",
        ↪fontSize=11,
        fontweight="bold", color=TEAL if x == 0 else ORANGE)
    ax.set_xticks([0, 1]); ax.set_xticklabels(["Ecuador", nombre], fontsize=10)
    ax.set_ylim(0, max(e, c) * 1.25)
    ax.set_title(nom + (" (menos es mejor)" if low else ""), fontsize=10.5,
    ↪color=INK, pad=6)
    for s in ["top", "right", "left"]:
        ax.spines[s].set_visible(False)
    ax.spines["bottom"].set_color("#ccc"); ax.set_yticks([]); ax.
    ↪tick_params(axis="x", length=0)
fig.subplots_adjust(top=0.83, bottom=0.10, hspace=0.5, wspace=0.22, left=0.05,
    ↪right=0.97)

```

```

fig.text(0.02, 0.975, "¿Qué separa a Ecuador del país mejor educado de la
↪ región?",
        va="top", ha="left", fontsize=15.5, fontweight="bold", color=INK)
fig.text(0.02, 0.90, f"Ecuador frente a {nombre} (el mayor aprendizaje de
↪ América Latina) en seis "
        "factores estructurales", va="top", ha="left", fontsize=10.3,
        ↪ color=GRAY)
fig.text(0.02, 0.02,
        "Fuente: Banco Mundial, UNESCO-UIS y Our World in Data (último dato
↪ disponible por país). "
        "Diferencias descriptivas a nivel país, no causales. Elaborado por
↪ Paula Martillo Quintana.",
        va="bottom", ha="left", fontsize=7.8, color="#9a9a9a")
fig.savefig("figuras/08_ecuador_vs_mejor.png", dpi=200, bbox_inches="tight",
        ↪ facecolor="white")
plt.show()


```

Factores estructurales: Ecuador vs Chile (valores que alimentan el grafico)

Aprendizaje (LAYS, años)	ECU= 8.7	CHL= 9.4
Gasto educativo (% PIB)	ECU= 3.7	CHL= 4.9
Acceso a internet (% pob.)	ECU= 72.7	CHL= 94.5
Matrícula terciaria (% bruta)	ECU= 67.9	CHL= 104.7
Finaliz. secundaria alta (%)	ECU= 80.8	CHL= 92.7
Alumnos por docente	ECU= 23.3	CHL= 18.2

¿Qué separa a Ecuador del país mejor educado de la región?

Ecuador frente a Chile (el mayor aprendizaje de América Latina) en seis factores estructurales



Fuente: Banco Mundial, UNESCO-UIS y Our World in Data (último dato disponible por país). Diferencias descriptivas a nivel país, no causales. Elaborado por Paula Martillo Quintana.

Lo que veo. El código primero calcula qué país de la región aprende más (medido en años de escolaridad ajustados por aprendizaje) y la respuesta es Chile. Al compararlo con Ecuador en seis condiciones estructurales, Ecuador queda por detrás en todas las que conviene tener altas: aprendizaje (8.7 frente a 9.4), gasto educativo (3.8% frente a 4.9% del PIB), acceso a internet (73% frente a 94%), matrícula en educación superior (68% frente a 105%) y finalización del bachillerato (81% frente a 93%); y por encima en la única que conviene tener baja, alumnos por docente (23 frente a 18). Esta es la respuesta más directa a mi pregunta: lo que separa a Ecuador del país que mejor educa en la región no es solo el resultado, son las condiciones con las que se estudia. Es una comparación entre países, así que describe diferencias, no demuestra causas.

5 Parte 4. Conclusión

Juntando lo que fui encontrando, la historia es coherente en los tres frentes que me propuse mirar.

Dentro de Ecuador, cuánto aprende un estudiante depende fuertemente de su origen: el nivel socioeconómico de la familia, la provincia donde estudia, el tipo de escuela y la etnia marcan diferencias grandes y consistentes. La brecha entre el quintil más rico y el más pobre equivale a cerca de dos años de escolaridad, y no es cosa de unos pocos casos extremos: toda la distribución de notas se corre hacia arriba a medida que sube el nivel socioeconómico.

Hacia afuera, cuando comparo con la misma prueba regional, Ecuador rinde a media tabla y arrastra una debilidad clara en lectura. Y frente a Chile, el país que mejor educa en la región, queda por detrás en cada condición estructural que pude medir.

Ese rezago importa porque la educación abre puertas: en los datos de empleo, cada nivel educativo alcanzado se asocia con ingresos marcadamente mayores. Si el aprendizaje depende tanto del origen, esas desigualdades tienden a perpetuarse en las oportunidades de la siguiente etapa.

En una frase: Ecuador no solo aprende menos que los líderes de la región como Chile, Costa Rica o México, sino que lo hace de forma más desigual hacia adentro, sobre todo en lectura y en el acceso a recursos (inversión, conectividad, educación superior). Esa combinación es la que puede traducirse en menos oportunidades a futuro: empleo, ingresos y acceso a la educación superior.

Vale recordar hasta dónde llega lo que muestro: trabajé con datos transversales (una foto, no un seguimiento de las mismas personas), los factores están relacionados entre sí, y no puedo enlazar la nota de un estudiante con su salario años después. Por eso hablo de patrones y asociaciones, no de causas. Aun con esos límites, la dirección de todos los indicios apunta al mismo lado.

5.0.1 Gráfico de cierre. El tamaño de la brecha

Para cerrar, un solo indicador comparable resume la conclusión: los años de escolaridad ajustados por aprendizaje (LAYS), que combinan cuánto se estudia y cuánto se aprende. Sitúa a Ecuador frente al promedio regional, al líder de la región y a la frontera mundial.

```
[49]: ref = {  
    "Ecuador": panel.loc["ECU", "LAYS"],  
    "Promedio\nAmérica Latina": lays_latam.mean(),  
    f"{nombre}\n(líder regional)": lays_latam.iloc[0],
```



```

    "Frontera mundial\n(Finlandia, Corea)": panel.loc[["FIN", "KOR"], "LAYS"].
    ↪mean(),
}
print("LAYS (años efectivos de aprendizaje):")
for k, v in ref.items():
    print(f" {k.replace(chr(10), ' '):28s} {v:.1f}")

items = sorted(ref.items(), key=lambda kv: kv[1])
labels, vals = [k for k, _ in items], [v for _, v in items]
colors = [DARK if "Ecuador" in k else (ORANGE if "Frontera" in k else TEAL) for
    ↪k in labels]

fig, ax = plt.subplots(figsize=(8.6, 4.6))
for i, (v, c) in enumerate(zip(vals, colors)):
    ax.plot([0, v], [i, i], color=c, lw=2, alpha=0.5, zorder=2)
    ax.scatter(v, i, s=150, color=c, zorder=3)
    ax.text(v + 0.32, i, f"{v:.1f}", va="center", ha="left", fontsize=11.5,
    ↪fontweight="bold", color=c)
ax.set_yticks(range(len(labels))); ax.set_yticklabels(labels, fontsize=10.5)
ax.set_xlim(0, 13); ax.set_xlabel("Años de escolaridad ajustados por
    ↪aprendizaje (LAYS)", color=GRAY)
estilo(ax); ax.tick_params(axis="y", length=0); ax.xaxis.grid(True,
    ↪color="#ECECEC")
encabezado(fig, "Ecuador está cerca del promedio regional,\npero lejos de la
    ↪frontera del aprendizaje",
            "Años de escolaridad ajustados por aprendizaje (LAYS): cuánto
    ↪aprende realmente cada país",
            "Fuente: Our World in Data (LAYS, último dato por país). Promedio y
    ↪líder regional sobre 19 países de América Latina. Elaborado por Paula
    ↪Martillo Quintana.",
            left=0.27)
fig.savefig("figuras/09_sintesis_brecha.png", dpi=200, bbox_inches="tight",
    ↪facecolor="white")
plt.show()


```

LAYS (años efectivos de aprendizaje):

Ecuador	8.7
Promedio América Latina	7.8
Chile (líder regional)	9.4
Frontera mundial (Finlandia, Corea)	11.7

Ecuador está cerca del promedio regional, pero lejos de la frontera del aprendizaje

Años de escolaridad ajustados por aprendizaje (LAYS): cuánto aprende realmente cada país



Fuente: Our World in Data (LAYS, último dato por país). Promedio y líder regional sobre 19 países de América Latina. Elaborado por Paula Martillo Quintana.

Ecuador (8.7) supera ligeramente al promedio de América Latina (7.8), pero queda por debajo del líder regional, Chile (9.4), y muy lejos de la frontera mundial (cerca de 11.7). Esa distancia, del orden de tres años de aprendizaje frente a los mejores, es la brecha que el país necesitaría cerrar, y resume las desigualdades que fui documentando a lo largo del trabajo.